

# Primeira avaliação (A1)

Disciplina: Inferência Estatística (MSc)

Instrutor: Luiz Max Carvalho

Monitor: Lucas Moschen

27 de Julho de 2022.

- O tempo para realização da prova é de 3 horas e 55 minutos;
- Leia a prova toda com calma antes de começar a responder;
- Responda todas as questões sucintamente;
- Marque a resposta final claramente com um quadrado, círculo ou figura geométrica de sua preferência;
- A prova vale 100 pontos. A pontuação restante é contada como bônus;
- Apenas tente resolver a questão bônus quando tiver resolvido todo o resto;
- Como convenção adotamos  $\mathbb{R} = (-\infty, \infty)$ ,  $\mathbb{R}_+ = (0, \infty)$  e  $\mathbb{N} = \{1, 2, \dots\}$ .

## 1. Uniformly cool.

Seja  $\mathbf{X}_n = (X_1, X_2, \dots, X_n)$  uma amostra aleatória de uma distribuição uniforme em  $(0, \theta]$  com densidade comum com respeito a Lebesgue

$$f_\theta(x) = \frac{1}{\theta} \mathbb{I}(0 < x \leq \theta).$$

Defina  $m := \min(\mathbf{X}_n)$  e  $M := \max(\mathbf{X}_n)$ .

- a) (20 pontos) Encontre o estimador de máxima verossimilhança para  $\theta$  e mostre que ele é suficiente e completo. Discuta se este estimador é viesado e se é consistente.
- b) (10 pontos) Mostre que  $U = \frac{m}{M}$  é ancilar.

**Dica:** Para uma amostra aleatória de tamanho  $n$  com cdf comum  $F$  e  $a < b$ , vale

$$\Pr(m \leq a, M \leq b) = [F(a)]^n - [F(b) - F(a)]^n.$$

- c) (10 pontos) Calcule  $E_\theta[U]$ .

**Dica:** Compute  $E_\theta[m]$  e lembre-se de que se  $X$  e  $Y$  são v.a.s independentes,  $E[XY] = E[X]E[Y]$ .

**Conceitos trabalhados:** estimador de máxima verossimilhança; suficiência; ancilaridade; Teorema de Basu.

**Nível de dificuldade:** médio.

**Resolução:** Primeiro vamos escrever a função de densidade de probabilidade conjunta da amostra observada:

$$\begin{aligned} f_\theta(\mathbf{x}_n) &= \prod_{i=1}^n f_\theta(x_i) \quad (\text{i.i.d.}), \\ &= \prod_{i=1}^n \frac{1}{\theta} \mathbb{I}(x_i > 0) \mathbb{I}(x_i \leq \theta), \\ &= \frac{1}{\theta^n} \prod_{i=1}^n \mathbb{I}\left(\min_i x_i > 0\right) \mathbb{I}\left(\max_i x_i \leq \theta\right). \end{aligned}$$

Assim, fazendo  $L_n(\theta) = f_\theta(\mathbf{x}_n)$  a nossa função de verossimilhança, vemos (Figura 1) que esta função é decrescente no intervalo  $[\max_i x_i, \infty)$  e, portanto,

$$\sup_{\theta \in (0, \infty)} L_n(\theta) = L_n(\max_i x_i) = \frac{1}{(\max_i x_i)^n}.$$

Desta forma, dizemos que  $\hat{\theta}_{\text{EMV}} = M$ . Pelo teorema da fatorização de Neyman-Fisher, sabemos que todo EMV é suficiente, o que também pode ser verificado diretamente por inspeção da função de verossimilhança. Para verificar completude, precisamos verificar que para  $g$  mensurável vale

$$E_\theta[g(M)] = 0 \implies g(x) = 0 \quad \forall x \in E,$$




Figura 1: **Função de verossimilhança para uma uniforme em  $(0, \theta]$ .** Aqui mostramos a verossimilhança para  $n = 10$ . Como podemos notar, a função é zero até  $M = \max_i X_i$  (linha vertical pontilhada). A partir deste ponto a função é decrescente e  $\propto \theta^{-n}$ .

com  $P_\theta(M \in E) = 1$  para todo  $\theta \in (0, \infty)$ . Primeiro, note que

$$F_M(y) = P_\theta(X_1 \leq y, X_2 \leq y, \dots, X_n \leq y) = \prod_{i=1}^n P_\theta(X_i \leq y) = \left[\frac{y}{\theta}\right]^n.$$

Assim,

$$f_M(y) = \frac{dF_M(y)}{dy} = \frac{n}{\theta} \left[\frac{y}{\theta}\right]^{n-1}.$$

Assim temos que, se  $M$  é completa,

$$E_\theta[g(M)] = \frac{n}{\theta^n} \int_0^\theta g(y) y^{n-1} dy = 0.$$

Defina  $K : \mathbb{R}_+ \rightarrow \mathbb{R}_+ \cup \{0\}$ ,

$$K(\theta) = \int_0^\theta g(y) y^{n-1} dy.$$

Pela regra de Leibniz, temos

$$\frac{d}{d\theta} K(\theta) = g(\theta) \theta^n.$$

Ora, se  $\frac{d}{dx}K(x) = 0$  para todo  $x$ , há de ser o caso de que  $g(x) = 0$  para todo  $x$  – a menos, talvez, de um conjunto de medida nula –, o que é exatamente o que queríamos demonstrar. Para entender o viés deste estimador, vamos calcular  $E_\theta[M]$ .

$$E_\theta[M] = \frac{n}{\theta^n} \int_0^\theta y y^{n-1} dy = \frac{n}{\theta^n} \frac{\theta^{n+1}}{n+1} = \frac{n}{n+1} \theta.$$

Outro caminho é utilizar a fórmula de cauda para a esperança (Lo, 2018),  $E_\theta[M] = \int_0^\infty \Pr(M > y) dy = \int_0^\infty [1 - F_M(y)] dy$ :

$$\begin{aligned} E_\theta[M] &= \int_0^\infty \left[1 - \left[\frac{y}{\theta}\right]^n\right] dy, \\ &= \int_0^\theta \left[1 - \left[\frac{y}{\theta}\right]^n\right] dy + \int_\theta^\infty \left[1 - \left[\frac{y}{\theta}\right]^n\right] dy, \\ &= \int_0^\theta 1 dy - \frac{1}{\theta^n} \int_0^\theta y^n dy \\ &= \theta - \frac{\theta^{n+1}}{(n+1)\theta^n} = \frac{n}{n+1} \theta. \end{aligned}$$

Para finalizar, vamos pensar sobre a consistência deste estimador. Tudo que precisamos é calcular, para  $\epsilon > 0$ ,

$$\begin{aligned} \lim_{n \rightarrow \infty} P_\theta(|M - \theta| > \epsilon) &= \lim_{n \rightarrow \infty} P_\theta(\theta - \epsilon \leq M \leq \theta + \epsilon), \\ &= \lim_{n \rightarrow \infty} \{P_\theta(M \leq \theta) - P_\theta(M \leq \theta - \epsilon)\}, \\ &= \lim_{n \rightarrow \infty} 1 - \left[\frac{\theta - \epsilon}{\theta}\right]^n = 1, \end{aligned}$$

portanto  $M \xrightarrow{p} \theta$ . Outra maneira de ver esse resultado é notar que  $M$  é assintoticamente não-viesado e que  $\lim_{n \rightarrow \infty} \text{Var}_\theta(M) = 0$ . Ora, por Chebychev, temos que para  $\epsilon > 0$

$$P_\theta(|M - \theta| \geq \epsilon) \leq \frac{E_\theta[(M - \theta)^2]}{\epsilon^2}.$$

Como o lado direito vai pra zero com  $n \rightarrow \infty$ , temos o resultado<sup>1</sup>. Agora vamos responder b) mostrando que a distribuição de  $U = m/M$  não depende de  $\theta$ . Em primeiro lugar, vamos usar a dica para encontrar

$$P_\theta(m \leq a, M \leq b) = \left[\frac{b}{\theta}\right]^n - \left[\frac{b}{\theta} - \frac{a}{\theta}\right]^n.$$

Diferenciando, encontramos

$$f_\theta(a, b) = \frac{n(n-1)}{\theta^n} [b - a]^{n-2}, 0 < a < b \leq \theta.$$

Para encontrar a distribuição de  $U$  precisamos considerar transformações das variáveis aleatórias  $m$  e  $M$ . Como  $U$  é uma função de  $\mathbb{R}_+^2$  em  $\mathbb{R}_+$ , vamos

<sup>1</sup>Ou seja, convergência quadrática implica convergência em probabilidade – como visto em aula e Keener (2010), prop 8.3. Isto por sua vez significa que não-viesamento assintótico + variância assintótica zero  $\implies$  consistência. Ver <https://stats.stackexchange.com/a/500762/97431>

“suplementar” o mapa com uma coordenada a mais, fazendo assim  $(m, M) \mapsto (U, M)$ . A matriz jacobiana da transformação é

$$J = \begin{bmatrix} M & U \\ 0 & 1 \end{bmatrix},$$

e temos que  $m = UM$ ,  $f_{U,M}(u, b) = f_\theta(a, b)|J|$ , ou seja,

$$f_{U,M}(u, b) = \frac{n(n-1)}{\theta^n} [b - ub]^{n-2} b = \frac{n(n-1)}{\theta^n} b^{n-1} [1 - u]^{n-2}.$$

Agora falta integrar com respeito a  $M$  para obter

$$\begin{aligned} f_U(u) &= \int_0^\theta f_{U,M}(u, b) db, \\ &= \frac{n(n-1)}{\theta^n} [1 - u]^{n-2} \int_0^\theta b^{n-1} db, \\ &= (n-1) [1 - u]^{n-2}, \end{aligned}$$

o que indica que, de fato, a densidade marginal de  $U$  não depende de  $\theta$  e portanto esta estatística é ancilar. Lucas nos aponta que uma maneira mais simples de ver o problema é notar que  $Y_i = X_i/\theta$  tem distribuição uniforme em  $(0, 1)$ , e assim  $U = M_y/m_y = (M/\theta)/(m/\theta)$  é a razão de duas quantidades que não dependem de  $\theta$ . Variáveis aleatórias como  $M/\theta$  e  $m/\theta$  são chamadas quantidades pivotais ou pivôs, e serão úteis mais à frente no curso. Para concluir a questão, vamos responder c). Primeiro, vamos seguir a dica e computar  $E_\theta[m]$ :

$$P_\theta(m \leq a) = 1 - \prod_{i=1}^n P_\theta(X_i > a) = 1 - \left[1 - \frac{a}{\theta}\right]^n.$$

Utilizando a fórmula de cauda e a substituição  $u = 1 - x/\theta$ , temos

$$E_\theta[m] = \int_0^\theta \left[1 - \frac{x}{\theta}\right]^n dx = \frac{\theta}{n+1}.$$

Como  $M$  é completa e suficiente e  $U$  é ancilar, temos que elas são independentes pelo Teorema de Basu, e portanto,

$$E_\theta \left[ \frac{m}{M} \right] = E_\theta[m] = \frac{\theta}{n+1} = E_\theta[U] E_\theta[M] = E_\theta[U] \frac{n}{n+1} \theta,$$

o que nos leva a concluir que

$$E_\theta[U] = \frac{1}{n}.$$

Esta quantidade é independente de  $\theta$ , o que era de se esperar dada a sua ancilaridade. Podemos também notar que  $f_U$  é a densidade de uma distribuição beta com parâmetros  $\alpha = 1$  e  $\beta = n - 1$  e então computar  $\alpha/(\alpha + \beta) = 1/n$ .

**Discussão:** Nesta questão respondemos algumas perguntas simples sobre um modelo que foi bastante estudado durante as aulas. A questão c) mostra a utilidade do teorema de Basu, que permite intuir a resposta sem necessariamente fazer a integração de  $f_U$ , que, se não soubéssemos que é uma densidade beta, daria um certo trabalho para integrar. ■

## 2. So many dice...

Seja  $\mathbf{X}_n = (X_1, X_2, \dots, X_n)$  uma amostra aleatória de uma distribuição binomial com número de tentativas  $N \in \mathbb{N}$  conhecido e probabilidade de sucesso  $\theta \in (0, 1)$  desconhecida. Considere estimar a probabilidade de exatamente um sucesso:

$$g(\theta) := P_\theta(X = 1) = N\theta(1 - \theta)^{N-1}.$$

- (10 pontos) Mostre que  $\delta_1(\mathbf{X}_n) = \mathbb{I}(X_1 = 1)$  é um estimador não-viesado de  $g(\theta)$ ;
- (10 pontos) Encontre uma estatística suficiente e completa,  $T(\mathbf{X}_n)$ .
- (10 pontos) Argumente que  $\delta_1$  não é suficiente e que portanto pode ser melhorado usando  $T$ . Mostre como fazer isso e obter um estimador  $\delta_2(\mathbf{X}_n)$ .
- (10 pontos) Exiba a fórmula para  $\delta_2$  e mostre que ele é ENNVUM.

**Conceitos trabalhados:** Rao-Blackwell; Estimador não-viesado de variância uniformemente mínima (ENNVUM); Lehmann-Scheffé.

**Nível de dificuldade:** fácil.

**Resolução:** A resolução aqui vai seguir bem de perto a apresentação do exemplo 7.3.24 de Casella and Berger (2002). Para começar, vamos notar que para calcular o viés de  $\delta_1$  só precisamos da distribuição de  $X_1$  e que  $E_\theta[\delta_1]$  vale

$$\begin{aligned} E_\theta[\delta_1] &= \sum_{x_1=0}^n \mathbb{I}(x_1 = 1) \binom{N}{x_1} \theta^{x_1} (1 - \theta)^{N-x_1}, \\ &= \binom{N}{1} \theta^1 (1 - \theta)^{N-1}, \\ &= g(\theta). \end{aligned}$$

*Easy-peasy.* Agora, vamos pensar em encontrar  $T$  suficiente e completa. Primeiro, vamos escrever a verossimilhança:

$$\begin{aligned} L_n(\theta) &= P_\theta(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n P_\theta(X_i = x_i), \\ &= \prod_{i=1}^n \binom{N}{x_i} (1 - \theta)^N \left( \frac{\theta}{1 - \theta} \right)^{x_i}, \\ &\propto_\theta (1 - \theta)^{nN} \left( \frac{\theta}{1 - \theta} \right)^{\sum_{i=1}^n x_i}, \end{aligned}$$

o que imediatamente sugere que  $T(\mathbf{X}_n) = \sum_{i=1}^n X_i$  é suficiente pelo Teorema da fatorização. Vamos derivar a distribuição de  $T$  para em seguida verificar se ela é completa. Se  $X$  é v.a. binomial com parâmetros  $k \in \mathbb{N}$  e  $p \in (0, 1)$ , então a sua função geradora de probabilidades (PGF) vale

$$\Pi_X(s) = (1 - p + ps)^k.$$

Para encontrar a PGF da soma de  $n$  v.a.s independentes<sup>2</sup>, podemos fazer

$$\Pi_{\sum_{i=1}^n X_i}(s) = \prod_{i=1}^n \Pi_{X_i}(s),$$

<sup>2</sup>Note que nada foi dito sobre identidade de distribuição.

o que nos leva a concluir que

$$\begin{aligned}\Pi_T(s) &= \prod_{i=1}^n (1 - \theta + \theta s)^N, \\ &= (1 - \theta + \theta s)^{nN},\end{aligned}$$

o que sugere que  $T$  tem distribuição binomial com parâmetros  $nN$  e  $\theta$ . Assim, precisamos verificar que para  $g$  mensurável, temos que

$$E_\theta[g(T)] = \sum_{t=0}^{nN} g(t) \binom{nN}{t} (1 - \theta)^{nN} \left( \frac{\theta}{1 - \theta} \right)^t = 0 \quad (1)$$

implica que  $g(t) = 0$  para  $t = 0, 1, \dots, nN$ . Como visto em aula em algumas oportunidades, a soma em (1) é um polinômio em  $\theta \in (0, 1)$ , o que implica que para que esta expressão seja indenticamente zero para todo  $\theta$  os coeficientes do polinômio em questão precisam ser zero, o que ocorre precisamente quando  $g(t) = 0$  para  $t \in \{0, 1, \dots, nN\}$ , que é o conjunto de medida 1 relevante. Todo esse desenvolvimento poderia ser pulado se notássemos que a família binomial é uma família exponencial com espaço paramétrico que contém um intervalo aberto de  $\mathbb{R}^s$ . Isto significa que  $T$  é suficiente e completa – ver Teorema 2.74 de Schervish (1995). Respondida a questão b), vamos agora melhorar  $\delta_1$  usando  $T$ . Isso vai ser legal, já que como  $\delta_1$  é não-viesado, vamos obter  $\delta_2$  também não-viesado! Está claro que queremos

$$\delta_2(\mathbf{X}_n) = E_\theta[\delta_1 \mid T] = E[\delta_1 \mid T],$$

onde a última igualdade segue do fato de que  $T$  é suficiente. Agora, procedemos aos cálculos, tomando  $T(\mathbf{X}_n) = t$ ,

$$\begin{aligned}\delta_2(\mathbf{X}_n) &= E[\delta_1 \mid T = t] = \Pr(X_1 = 1 \mid T = t), \\ &= \frac{P_\theta(X_1 = 1, T = t)}{P_\theta(T = t)}, \\ &= \frac{P_\theta(X_1 = 1) P_\theta(\sum_{i=2}^n X_i = t - 1)}{P_\theta(T = t)}, \\ &= \frac{\left\{ \binom{N}{1} \theta^1 (1 - \theta)^{N-1} \right\} \left\{ \binom{(n-1)N}{t-1} \theta^{t-1} (1 - \theta)^{(n-1)N-t+1} \right\}}{\binom{nN}{t} \theta^t (1 - \theta)^{nN-t}}.\end{aligned}$$

Depois de alguma álgebra, encontramos

$$\delta_2(\mathbf{X}_n) = \frac{N \binom{(n-1)N}{T-1}}{\binom{nN}{T}},$$

que naturalmente não depende de  $\theta$ , já que  $T$  é suficiente para  $\theta$ . A Figura 2 mostra a distribuição de  $\delta_1$  e  $\delta_2$ . Para terminar de responder à questão d), notamos que como  $T$  é completa e suficiente, o Teorema de Lehmann-Scheffé não só garante que  $\delta_2$  é o ENVVUM como também que é único!




Figura 2: **Distribuição dos estimadores  $\delta_1$  e  $\delta_2$  no exemplo da binomial.** Aqui  $N = 20$ ,  $n = 50$  e  $\theta_0 = .234$ , o que dá  $g(\theta_0) \approx 0.0295$ . Resultados obtidos com cem mil replicatas de Monte Carlo.

**Discussão:** Nesta questão vimos como melhorar um estimador não-viesado de uma quantidade complicada através do mecanismo de Rao-Blackwell. Utilizando Lehmann-Scheffé, conseguimos fazer uma afirmação interessante sobre as propriedades do estimador melhorado,  $\delta_2$ . Agora, uma observação adicional: note que sem acesso a Lehmann-Scheffé, poderíamos tentar demonstrar que<sup>3</sup>

$$\text{Var}_\theta(\delta_2) = \frac{[g'(\theta)]^2}{nI(\theta)},$$

isto é, que  $\delta_2$  atinge a cota inferior de Cramér-Rao (CLRB). Além de parecer um problema difícil de resolver em forma fechada, há também o fato de que a variância de  $\delta_2$  é próxima da CLRB, mas não parece atingi-la (ver Tabela 1). Isso acontece porque um ENVVUM não necessariamente atinge a cota inferior de Cramér-Rao. E este parece ser o caso aqui. ■

---

<sup>3</sup>Aqui nós “corrigimos” a expressão para levar em conta que estamos estimando  $g(\theta)$  e não  $\theta$ .



Tabela 1: **Simulação da Binomial com  $N = 20$  e  $n = 50$ .** Resultados obtidos com cem mil replicatas de Monte Carlo.

$\theta_0$	$\text{Var}_\theta(\delta_1)$	$\text{Var}_\theta(\delta_2)$	Cramér-Rao
0.1	1.97E-01	8.06E-04	8.11E-04
0.2	5.38E-02	1.90E-04	1.86E-04
0.3	7.26E-03	5.84E-06	5.56E-06
0.4	4.29E-04	5.26E-08	4.85E-08
0.5	1.99E-05	1.36E-10	1.17E-10
0.6	0.0	6.85E-14	5.48E-14
0.7	0.0	2.94E-18	2.13E-18
0.8	0.0	1.96E-24	9.89E-25
0.9	0.0	4.84E-35	1.04E-35

### 3. Exponentially efficient.

Dizemos que uma família de distribuições de probabilidade forma uma família exponencial regular de dimensão  $s$  se:

1. O suporte da distribuição,  $E = \{x : f_\theta(x) > 0\}$ , não depende de  $\theta$ ;
2. O espaço paramétrico  $\Theta$  é um subconjunto aberto de  $\mathbb{R}^s$ ;
3. Para todo vetor  $a = (a_1, \dots, a_s)$  diferente de  $\mathbf{0} = (0, \dots, 0)$  vale

$$P_\theta(a \cdot T(X) = a_s) < 1,$$

para todo  $\theta$ , ou seja, as estatísticas suficientes não são linearmente dependentes com probabilidade positiva.

Suponha que  $\mathbf{X}_n = (X_1, X_2, \dots, X_n)$  formam uma amostra aleatória de uma distribuição  $P_\theta$  pertencente a uma família exponencial regular de dimensão  $s = 1$  parametrizada em função da média, isto é,  $\theta = E[X]$ .

- a) (10 pontos) Encontre uma forma funcional para o estimador de máxima verossimilhança de  $\theta$  em função da estatística suficiente,  $T(\mathbf{X}_n)$ . Discuta as condições para que este estimador seja único.
- b) (10 pontos) Dizemos que um estimador  $\delta$  de  $g(\theta)$  é *eficiente* se a sua variância é igual à cota inferior de Cramér-Rao para todo  $\theta \in \Theta$ . Discuta se o estimador obtido no item anterior é eficiente.

**Dica:** Compute a informação de Fisher,  $I_X(\theta)$ , e lembre-se de ajeitar a parametrização.

**Conceitos trabalhados:** suficiência; família exponencial; reparametrização; Informação de Fisher.

**Nível de dificuldade:** médio.

**Resolução:** A discussão aqui vai seguir de perto o começo da seção 8.3 de Keener (2010). Primeiro, vamos expressar a densidade de  $P_\theta$  na forma canônica,

$$f_\eta(x) = h(x) \exp[\eta T(x) - A(\eta)],$$

e, portanto, a função *score* é

$$\begin{aligned}\kappa(\eta) &= \frac{\partial}{\partial \eta} \{ \eta T(x) - A(\eta) \}, \\ &= \frac{\partial}{\partial \eta} \eta T(x) - \frac{\partial}{\partial \eta} A(\eta).\end{aligned}$$

Agora, note que para uma amostra aleatória, temos

$$\begin{aligned}\kappa_n(\eta) &= \frac{\partial}{\partial \eta} \eta \sum_{i=1}^n T(x_i) - \frac{\partial}{\partial \eta} nA(\eta), \\ &= \sum_{i=1}^n T(x_i) - nE_\eta[T].\end{aligned}$$

Fazendo  $E_\eta[T] = m(\eta)$ , vemos que

$$m(\hat{\eta}) = \frac{1}{n} \sum_{i=1}^n T(x_i) =: \bar{T}_n.$$

Supondo que conseguimos inverter  $m$ , temos

$$\hat{\eta} = m^{-1}(\bar{T}_n).$$

Assim, concluímos que  $\hat{\theta}_{\text{EMV}} = \bar{T}_n$ . Ou seja, numa família exponencial regular, o estimador de máxima verossimilhança da média é a média amostral da estatística suficiente aplicada na amostra. Note que

$$\frac{\partial}{\partial \eta} \kappa_n(\eta) = -\frac{\partial^2}{\partial \eta^2} nA(\eta) = -n \text{Var}_\eta(T),$$

que é negativo quase certamente. Dessa forma, dada a convexidade do espaço paramétrico natural, sabemos que  $\hat{\eta}$  é único, e portanto  $\hat{\theta}_{\text{EMV}}$  também o é. Sabemos também que  $\hat{\theta}_{\text{EMV}}$  é não-viesado, já que

$$\begin{aligned}E_\eta[\hat{\theta}_{\text{EMV}}] &= \frac{1}{n} \sum_{i=1}^n E_\eta[T(X_i)], \\ &= \frac{1}{n} n\theta = \theta.\end{aligned}$$

Promissor no que toca à chance de ser eficiente! Agora vamos verificar se este estimador atinge a cota inferior de Cramér-Rao. Para isso, vamos seguir a dica e calcular a informação de Fisher. Primeiro, a forma canônica:

$$\begin{aligned}I_n(\eta) &= \text{Var}_\eta(\kappa_n(\eta)), \\ &= E_\theta[\{\kappa_n(\eta)\}^2], \\ &= E_\theta \left[ \left\{ \sum_{i=1}^n T(x_i) - n\theta \right\}^2 \right], \\ &= n \text{Var}_\eta[T(X)]\end{aligned}$$

Onde a segunda linha segue do fato de que a função *score* tem esperança zero e quarta envolve abrir o quadrado e agrupar, lembrando que  $\theta$  é a média de  $X$ . Agora, pela regra da cadeia, temos

$$\begin{aligned} I_n(\theta) &= \left[ \frac{d}{d\theta} h^{-1}(\theta) \right]^2 I_n(h^{-1}(\theta)), \\ &= \frac{1}{n \operatorname{Var}_\theta[T(X)]}, \end{aligned}$$

Onde a segunda linha segue do fato de que

$$\operatorname{Var}_\theta(T(X)) = \frac{\frac{\partial^2}{\partial \theta^2} A(\eta(\theta))}{[\eta'(\theta)]^2} - \frac{\frac{\partial}{\partial \theta} A(\eta(\theta)) \eta''(\theta)}{[\eta'(\theta)]^3}.$$

Mas  $n \operatorname{Var}_\eta[T(X)]$  é a variância de  $\hat{\theta}_{\text{EMV}}$  e portanto concluímos que ele atinge a CRLB e portanto é eficiente!

**Discussão:** nesta questão exploramos algumas propriedades adicionais da família exponencial, em particular a parametrização de média de famílias regulares. Vimos que há uma forma funcional simples para o EMV da média. Durante toda a derivação era preciso saber bem as identidades diferenciais da família exponencial e as propriedades da informação de Fisher. ■

## 4. (Bônus) I'm never enough for you!

A mediana amostral é definida como

$$m(\mathbf{X}_n) = \begin{cases} X_{(\frac{n+1}{2})}, & \text{se } n \text{ é ímpar,} \\ \frac{X_{(n/2)} + X_{(n/2+1)}}{2}, & \text{se } n \text{ é par.} \end{cases}$$

Tome  $\mathbf{X}_n = (X_1, X_2, \dots, X_n)$  uma amostra aleatória de uma distribuição qualquer,  $P_\theta$ .

a) (20 pontos) Mostre que para  $n > 2$ ,  $m(\mathbf{X}_n)$  **nunca** é estatística suficiente.

**Conceitos trabalhados:** estatísticas de ordem; suficiência; Pitman-Koopman-Darmois; família exponencial.

**Nível de dificuldade:** difícil.

**Resolução:** Quando  $n = 1, 2$ , média e mediana coincidem, e, portanto, a afirmação não pode valer, visto que sabemos de várias situações onde a média é, de fato, suficiente. Para  $n \geq 3$ , vamos começar com o caso mais difícil, que é quando o suporte de  $P_\theta$  depende de  $\theta$ . Nesta situação, podemos escrever

$$f_\theta(x) = h(x)t(\theta)\mathbb{I}(x \in A_\theta),$$

onde  $A_\theta \in \mathcal{X}$  é o suporte e  $t$  é uma função só de  $\theta \in \Theta$ . A densidade conjunta da amostra vale, portanto,

$$\begin{aligned} f_\theta(\mathbf{x}_n) &= \prod_{i=1}^n h(x_i)[t(\theta)]^n \prod_{i=1}^n \mathbb{I}(x_i \in A_\theta), \\ &= h_n(\mathbf{x}_n)[t(\theta)]^n \mathbb{I}(x_i \in A_\theta). \end{aligned}$$

Pelo Teorema da Fatorização, temos que

$$\mathbb{I}(m(\mathbf{x}_n) \in B_\theta^n) = \mathbb{I}(m(\mathbf{x}_n) \in B_\theta^n),$$

onde  $B_\theta^n \subseteq \mathcal{X}$  é justamente o conjunto cuja indicatriz coincide com  $\prod_{i=1}^n \mathbb{I}(x_i \in A_\theta)$  para as medianas de todas as amostras  $\mathbf{x}_n$  possíveis. Note que se a mediana é de fato suficiente,  $\mathbb{I}(m(\mathbf{x}_n) \in B_\theta^n)$  depende de  $\theta$  apenas através de  $B_\theta^n$ . Considere adicionar uma nova observação  $x_{n+1}$  à amostra e note que sempre é possível fazê-lo de modo a deixar  $m(\mathbf{x}_n)$  intacta. Claramente,

$$\mathbb{I}(m(\mathbf{x}_{n+1}) \in B_\theta^{n+1}) = \mathbb{I}(m(\mathbf{x}_n) \in B_\theta^n) \cdot \mathbb{I}(x_{n+1} \in A_\theta),$$

mas  $x_{n+1}$  pode estar dentro ou fora do suporte, o que leva a uma contradição! Suponha agora que  $E = \{x : f_\theta(x) > 0\}$  é independente de  $\theta$ . Neste caso, podemos invocar o Teorema de Pitman-Koopman-Darmois (Darmois, 1935; Pitman, 1936; Koopman, 1936), que diz que se uma família de distribuições de probabilidade tem suporte independente de  $\theta$  e tem estatística suficiente de dimensão finita, então esta é uma família exponencial. Ora, se  $P_\theta$  pertence à família exponencial, a densidade conjunta de  $\mathbf{X}_n = \mathbf{x}_n$  pode ser escrita como

$$\begin{aligned} f_n(\mathbf{x}_n) &= \prod_{i=1}^n f_\theta(x_i) = \prod_{i=1}^n h(x_i) \exp \left[ \sum_{j=1}^s \eta_j(\theta) T_j(x_i) - B(\theta) \right], \\ &= \exp \left[ \sum_{j=1}^s \eta_j(\theta) \sum_{i=1}^n T_j(x_i) - nB(\theta) \right] \prod_{i=1}^n h(x_i), \end{aligned}$$

o que sugere que  $T(\mathbf{X}_n) = (\sum_{i=1}^n T_1(x_i), \dots, \sum_{i=1}^n T_s(x_i))$  é estatística suficiente **mínima** para  $\theta$ . Sendo assim, a mediana deveria ser função de  $T(\mathbf{X}_n)$ , mas modificar um dos extremos em  $x_{(1)}, \dots, x_{(n)}$  certamente muda  $T(\mathbf{x}_n)$ , mas não muda  $m(\mathbf{x}_n)$ , o que é um absurdo. Concluimos, assim, que a mediana também não pode ser suficiente neste caso. ■

# Bibliografia

- Casella, G. and Berger, R. (2002). *Statistical inference*. Duxbury advanced series, second edition.
- Darmois, G. (1935). Sur les lois de probabilité à estimation exhaustive. *CR Acad. Sci. Paris*, 260(1265):85.
- Keener, R. W. (2010). *Theoretical Statistics: Topics for a core course*. Springer.
- Koopman, B. O. (1936). On distributions admitting a sufficient statistic. *Transactions of the American Mathematical society*, 39(3):399–409.
- Lo, A. (2018). Demystifying the integrated tail probability expectation formula. *The American Statistician*.
- Pitman, E. J. G. (1936). Sufficient statistics and intrinsic accuracy. In *Mathematical Proceedings of the Cambridge Philosophical Society*, volume 32, pages 567–579. Cambridge University Press.
- Schervish, M. J. (1995). *Theory of Statistics*. Springer Science & Business Media.